


ПРОЕКТ

NLP · RAG · QA



ShkereBERT

RAG-чат-бот по документу с извлечением источника и честной обработкой вопросов без ответа

Команда: Федорко Владимир · Бабюк Даниил · Сунгуртян Исак

ЗАДАЧА

Что нужно сделать

Чат-бот по документу

Отвечает на вопросы пользователя на основе содержимого текстового документа

Честность

Если ответа в документе нет — система прямо сообщает об этом, а не выдумывает

Источник

Каждый ответ сопровождается цитатой фрагмента-первоисточника

Оценка качества

Корректность измеряется стандартными метриками Exact Match и F1

Пайплайн RAG-системы



Полностью офлайн на CPU: данные не покидают периметр, что критично для контура безопасности.

Датасет: SQuAD v2

- 150k+ вопросов

Вопросы по статьям Wikipedia с аннотированными ответами-фрагментами

- ~50k adversarial вопросов без ответа



Уникальная особенность: вопросы, на которые в контексте нет ответа — модель должна это распознать

- Короткие контексты

Медиана — 141 токен. Ограничивает оценку стратегий чанкинга

Проблемы и решения

- Короткие контексты → дополнительный тест на длинных документах (eval_longdoc)
- Честная оценка → разделение calibration / test без утечки данных
- Стабильность → multi-seed оценка на 5 седах



МОДЕЛИ

Три модели — три роли

- all-MiniLM-L6-v2
Поиск — эмбединги для семантического ретривала. 22M параметров.
- tinyroberta-squad2
Чтение — извлечение span-ответа из фрагмента. 80M параметров.
- Qwen 2.5 3B
Генерация — свободный ответ с цитатами. 3B параметров.

Все модели предобученные — transfer learning без дообучения. Всё работает на CPU, офлайн.

Три режима ридера



Extractive (BERT)

Вырезает точный фрагмент текста.
Быстро — 50 мс на ответ. Точно и детерминированно.



Generative (Qwen)


Генерирует ответ своими словами с цитатами [1][2]. Может объединять информацию из нескольких фрагментов.



Hybrid

Qwen генерирует + BERT проверяет факты. Перехватывает ~70% галлюцинаций.

Качество поиска (Retrieval)



Ключевой вывод

Recall@5 = 94% — в 94% случаев нужный фрагмент попадает в пятёрку лучших.

Это обосновывает выбор **top_k = 5** как оптимального баланса между покрытием и шумом.

End-to-End QA

Setup	EM	F1	HasAns F1	NoAns F1
Наш пайплайн	73.6	75.8	66.2	84.6
Oracle (потолок)	79.1	81.0	76.9	84.9

Потеря на retrieval

5.2 пункта F1 — цена ошибки поиска. Room for improvement в ретривере.

Корректность реализации

Oracle F1 совпал с эталоном модели — реализация пайплайна корректна.

Что влияет на качество

- `chunk_size`

Тестировали 128, 256, 512 токенов — влияет на полноту фрагментов и F1


- `top_k`

Тестировали 1, 3, 5, 10 — баланс покрытия vs шума в контексте ридера

Оптимум: `top_k = 5`

F1 насыщается к `k=5` — дальнейшее увеличение `top_k` не даёт прироста качества.

Латентность при этом растёт линейно → `k=5` — оптимальный выбор.



Стабильность результатов



Доверительный интервал

Multi-seed оценка на 5 сидах

Multi-seed (5 сидов)

F1 = 76.9 ± 3.9 (95% CI). Наш результат 75.8 — внутри интервала.

Разница F1 (long doc)

chunk=64 vs chunk=256 — значимая разница

На длинных документах

chunk=64 даёт **F1 74.7** vs chunk=256 **F1 69.3** — разница 5 пунктов статистически значима.

❏ Разница между конфигурациями в 1–2 пункта F1 — шум выборки, а не реальное улучшение.

Источник документов

Что используем?

- ☒ Демо: SQuAD v2
- ☐ Свой файл (PDF/TXT)

Контекстов SQuAD



Загрузить корпус

Режим ридера

Как формировать ответ? ?

- ☒ extractive
- ☐ generative
- ☐ hybrid



ShkereBERT

RAG-чат-бот по документу с цитированием источника и обработкой «нет ответа».

Ваш вопрос

How much people lives in California

Ответ: 22,680,010

[extractive] confidence = 8.49 · answer extracted

Источники

- ▼ ★ [sq-02d25619e58a::0] score=0.663 

As of the 2010 United States Census, southern California has a population of 22,680,010. Despite a reputation for high growth rates, southern California's rate grew less than the state average of 10.0% in the 2000s as California's growth became concentrated in the northern part of the state due to a stronger, tech-oriented economy in the Bay Area and an emerging Greater Sacramento region.
- > [sq-320c4604554f::0] score=0.661
- > [sq-dba8de6724ec::0] score=0.603
- > [sq-b3195de1d69d::0] score=0.586
- > [sq-2e560fa62217::0] score=0.477



ИТОГИ

ИТОГИ И ВЫВОДЫ

Что сделали

- RAG-пайплайн с 3 режимами ридера и защитой от галлюцинаций
- Честная оценка: calibration/test, oracle-baseline, multi-seed
- Всё офлайн на CPU — готово для on-premise

Что можно улучшить

- Русский экстрактивный ридер (xlm-roberta)
- GPU для ускорения Qwen (10 с → 0.5 с)
- OCR для PDF-сканов